LIQUID COMMODITIES LAB

Le projet de A à Z : la question, les données, les modèles, les résultats et le site.

Projet individuel, Machine Learning with R, emlyon business school. État au 17 octobre 2026 (sessions 1 à 10).

1 Le projet en une page

La question. Des variables externes (géopolitique, stocks, météo) combinées au machine learning prévoient-elles mieux la volatilité des matières premières que le modèle de référence HAR ? Et une meilleure prévision aide-t-elle un gérant qui veut garder son risque à un niveau fixe ?

Le terrain. Cinq ETF, un par matière première : GLD (or), USO (pétrole), CPER (cuivre), UNG (gaz naturel) et CORN (maïs), de 2011 à octobre 2026. La cible est la volatilité des 21 prochains jours de bourse. On cherche à contrôler le risque, pas à prédire les prix.

1. HAR n'est pas battu en moyenne

Sur les cinq actifs réunis, aucun modèle de machine learning ne fait mieux, et l'écart est statistiquement significatif.

2. Une exception solide : le pétrole

Un Lasso qui utilise la volatilité implicite (OVX) réduit la perte de prévision d'environ 20 %, significatif à 1 %, 9 années sur 10.

3. Piloter le risque crée la valeur

Le vol targeting ramène la volatilité de 31 % à environ 10 %, quel que soit le modèle. Le meilleur modèle dépend de l'horizon de décision.

Ce qui a été construit. Un pipeline en R, de la collecte des données au backtest, couvert par 109 tests automatiques, versionné sur GitHub ; puis un site web statique qui présente les résultats, alimenté uniquement par des fichiers exportés depuis R.

`01_data.R`
Données
Téléchargement et cache de 13 séries

`02_features.R`
Table
Cible et variables, datées au jour de leur publication

`03 + 04`
Modèles
Naïf, EWMA, HAR, Lasso, forêt ; validation chronologique

`05_inference.R`
Tests
Diebold-Mariano, Mincer-Zarnowitz

`06 + 07`
Valeur
Backtest, portefeuille, robustesse

`08_export.R`
Site
Fichiers JSON lus par le site

2 Les données

Source	Contenu	Rôle dans le projet
Yahoo Finance	Prix quotidiens des 5 ETF et de UUP (dollar)	Cible, variables HAR, dollar
FRED	VIX, OVX (pétrole), GVZ (or)	Volatilité implicite, c'est-à-dire anticipée par les options
EIA (API, clé)	Stocks de brut et de gaz, hebdomadaires	Fondamentaux
Caldara et Iacoviello	Indice de risque géopolitique (GPR), quotidien	Géopolitique
Open-Meteo	Température de 10 villes américaines	Degrés-jours de chauffage (demande de gaz)

Cache. Chaque série est téléchargée une fois puis relue depuis `data/raw/`. Les données sont ainsi figées et les résultats reproductibles. Les clés API sont dans `.Renviron`, jamais sur GitHub.

Contrôle qualité. Deux découvertes ont changé le traitement. CPER est très peu échangé à ses débuts (329 jours sans aucun échange) et Yahoo contient un prix faux le 4 décembre 2014 (13,05 $ entre 19,52 $ et 19,56 $, volume nul). Règle retenue : un jour sans échange, on garde la clôture de la veille, puisqu'aucun prix n'a été réellement traité.

3 La règle centrale : n'utiliser que ce qui était connu

La faute la plus fréquente en finance quantitative est la fuite d'information : utiliser, à une date donnée, une donnée qui n'était pas encore publiée. Le modèle paraît alors excellent dans le passé et échoue en réalité. Ici, chaque valeur reçoit une **date de disponibilité** : le premier jour où elle était connue à la clôture.

Valeurs décrivant le ven. 9 janv. 2015	ven 9	sam 10	dim 11	lun 12	mar 13	mer 14	jeu 15	ven 16
Prix de clôture des ETF	**utilisable**							
Volatilité implicite, météo	mesurée			**utilisable**				
Risque géopolitique (mis à jour le lundi)	mesuré			publié		**utilisable**		
Stocks de brut (EIA)	mesurés					publiés	**utilisables**	
Stockage de gaz (EIA)	mesuré						publié	**utilisable**

Une fonction de « jointure à la date » (`asof_join`, l'équivalent de `pd.merge_asof`) rattache chaque jour de bourse à la dernière valeur déjà disponible. Le cas du GPR est instructif : le fichier quotidien n'est mis à jour qu'une fois par semaine, donc un simple décalage d'un jour aurait laissé une fuite.

Comment on le prouve : les tests

- **Perturbation :** on modifie un seul rendement et on vérifie que seules les bonnes lignes bougent (la cible du jour t utilise les jours t+1 à t+21, jamais t ni t+22).
- **Dates de publication :** le mercredi de la publication EIA, la variable vaut encore la semaine précédente ; le jeudi, elle change.
- **Millésime :** on reconstruit toute la table avec les seules données publiées à une date donnée ; tout ce qui précède cette date doit être identique. Ce test a été lui-même vérifié en injectant volontairement quatre fuites : il les détecte toutes.

4 La cible, les variables et les modèles

Cible. Le logarithme de la volatilité réalisée sur les 21 jours suivants : √(252 × moyenne des rendements journaliers au carré). On prend les rendements de clôture, ceux que subit réellement le gérant.

Bloc de variables	Contenu
Rendements propres (B1)	Volatilité des 1, 5 et 22 derniers jours (HAR), rendements négatifs, EWMA
Volatilité implicite (B2)	OVX pour le pétrole, GVZ pour l'or, VIX pour tous
Géopolitique (B3)	Niveau du GPR sur 7 et 30 jours, et leur écart
Fondamentaux (B4)	Stocks par rapport à leur moyenne des années passées, anomalie de degrés-jours, dollar

Modèle	Principe
Naïf	La vol du mois prochain égale celle des 22 derniers jours
EWMA	Moyenne exponentielle des rendements au carré (λ = 0,94), la référence des praticiens
HAR (Corsi, 2009)	Régression de la vol future sur les vols d'un jour, d'une semaine et d'un mois : **le modèle à battre**
Lasso	Régression linéaire qui sélectionne ses variables en mettant les autres à zéro
Random forest	Moyenne de nombreux arbres de décision : capte les effets non linéaires

5 La validation : simuler le passé honnêtement

Walk-forward. Chaque année de 2017 à 2026, les modèles sont estimés sur toutes les données disponibles jusque-là, puis prévoient l'année entière. L'année suivante, la fenêtre s'agrandit. Les modèles n'ont donc jamais vu la période qu'ils prévoient.

Embargo de 21 jours. La cible du jour t n'est connue qu'à t+21. On n'entraîne donc que sur les jours dont la cible était déjà connue au début de l'année de test. Le même principe s'applique au réglage du Lasso (validation croisée « purgée » par blocs contigus).

Choix figés à l'avance. Les réglages de la forêt ont été choisis sur 2015-2016 uniquement, et la comparaison principale (meilleur modèle contre HAR, sur les cinq actifs) a été fixée avant de regarder les résultats.

Mesurer la qualité d'une prévision

- **QLIKE :** perte principale, calculée sur la variance. Elle vaut 0 pour une prévision parfaite et pénalise davantage la sous-estimation du risque. Les résultats sont donnés en ratio à HAR : sous 1, le modèle fait mieux.
- **Correction de Jensen :** un modèle qui prévoit le log de la vol sous-estime la variance si on repasse simplement par l'exponentielle. HAR passe ainsi de 74 % à 88 % de la variance réalisée une fois corrigé.
- **Diebold-Mariano :** l'écart de perte avec HAR est-il plus grand que le hasard ? Les jours voisins se ressemblent (20 rendements futurs sur 21 en commun), d'où des erreurs-types de Newey-West, codées à la main et validées contre le package `sandwich`.
- **Mincer-Zarnowitz :** on régresse la réalité sur la prévision. Une pente au-dessus de 1 signale une prévision trop lisse, en dessous de 1 une prévision trop agitée.

6 Les résultats de prévision

Sur les cinq actifs réunis (2017-2026)

Modèle	Perte / HAR
HAR	1,00
Lasso, blocs par actif (B2)	1,05
Forêt, rendements seuls	1,08
Lasso, toutes variables	1,10
Forêt, toutes variables	1,11
EWMA	1,12
Naïf	1,26

Par actif, meilleur modèle

Actif	Meilleur	/ HAR
Pétrole	Lasso + OVX	0,80
Cuivre	Forêt + GPR	0,88
Or	EWMA	0,99
Gaz	HAR	1,00
Maïs	HAR	1,00

Cuivre : p = 0,09, non significatif. Or : égalité.

> **Lecture.** Seul le pétrole résiste aux tests (Diebold-Mariano −2,92, p = 0,0035). Le Lasso n'y garde qu'une variable sur dix-huit : l'OVX, la volatilité anticipée par les options sur USO. Le marché sait déjà : les variables externes n'aident que lorsqu'elles sont des **prix de marché**. Les stocks et la météo n'apportent rien, même pour le pétrole et le gaz. Avec environ 65 comparaisons, quelques « victoires » isolées sont attendues par hasard : on ne retient que ce qui est cohérent et significatif.

Pourquoi le machine learning perd ailleurs. Une forêt ne peut pas prévoir au-delà de ce qu'elle a déjà vu (elle plafonne en 2020) ; le Lasso, trop rétréci, rend des prévisions trop lisses (pente de Mincer-Zarnowitz de 1,17 à 1,67) ; donner toutes les variables à tous les actifs ajoute du bruit.

7 La valeur économique

La stratégie. Un gérant vise 10 % de volatilité : poids = 10 % / vol prévue, plafonné à 2. Rééquilibrage hebdomadaire seulement si l'écart dépasse 10 %, coûts de 5 points de base. Deux références encadrent les modèles : l'ETF détenu tel quel, et un « oracle » qui connaîtrait la vraie volatilité future.

Moyenne des 5 actifs	Vol réalisée	Jours > 15 %	Pire perte	Sharpe	Écart à la cible
ETF détenu tel quel	30,9 %	80 %	−58 %	0,33	0,221
Piloté avec EWMA	10,6 %	1,4 %	−24 %	0,41	0,017
Piloté avec HAR	10,3 %	2,4 %	−23 %	0,40	0,021
Piloté avec le Lasso (B2)	10,4 %	3,8 %	−24 %	0,37	0,027
Oracle (impossible)	10,0 %	0 %	−22 %	0,43	0,006

> **Deux leçons.** (1) Piloter le risque apporte l'essentiel de la valeur, quel que soit le modèle. (2) Le meilleur modèle statistique n'est pas le meilleur pour le portefeuille : EWMA tient mieux la cible que HAR. La raison est un décalage d'horizon. Les modèles prévoient 21 jours, mais on rééquilibre tous les 5 jours. Avec une prévision à 5 jours, l'avance d'EWMA fond de 61 % ; avec un rééquilibrage mensuel, de 84 %. **L'horizon de la prévision doit correspondre à celui de la décision.**

Portefeuille des cinq ETF. Pondéré par l'inverse des volatilités prévues et ramené à 10 %, il double le Sharpe d'un portefeuille équipondéré (0,66 à 0,77 contre 0,35) et divise par deux la pire perte (−19 % contre −39 %). Les

résultats ne changent pas avec les coûts (0 ou 20 points de base) ni avec la bande de non-transaction.

8 Le site

Architecture. Site statique (HTML, CSS, JavaScript) dans `site/`, choisi plutôt que Shiny pour la liberté visuelle, le chargement instantané et l'hébergement gratuit. R calcule tout ; `export_site.R` écrit six fichiers JSON dans `site/data/` ; le site ne fait que les afficher. Aucune donnée n'est inventée.

Fichier	Rôle
`index.html`	La structure de la page
`css/tokens.css`	Le système de design : couleurs, typographie, espacements, une couleur par matière
`css/main.css`	La mise en page et les composants
`js/hero.js`	L'ouverture : les vraies courbes de volatilité et la goutte de métal liquide (shader WebGL)
`js/main.js`	Le chargement des données, les cartes des matières et le graphique (D3)
`js/story.js`	Les quatre chapitres : risque, disponibilité des données, modèles, résultats

Le voir. En local avec l'extension Live Server de VS Code (« Go Live » sur `site/index.html`), ou sur la page d'aperçu privée mise à jour à chaque session. Mise en ligne prévue sur GitHub Pages en fin de projet.

9 Limites et suite

Limites assumées

- Environ 120 observations indépendantes par actif : tests de faible puissance.
- GPR et météo sont révisés après coup ; pas de version « temps réel ».
- Cash rémunéré à 0 % et levier gratuit dans le backtest.
- USO a changé de méthode de roulement en 2020.
- Police One Slice : licence à régler avant la mise en ligne.

Prochaines étapes

- S11 : tableau de bord (prévisions contre réalité, valeur économique).
- S12 : simulateur de portefeuille en JavaScript, validé contre R.
- S13 : méthodologie, mobile, accessibilité, mise en ligne.
- Puis : Lasso et random forest codés à la main, validés contre glmnet et ranger.

Mini-glossaire

Volatilité réalisée	Écart-type annualisé des rendements journaliers observés
Volatilité implicite	Volatilité anticipée par le prix des options (VIX, OVX, GVZ)
Fuite d'information	Utiliser une donnée avant sa publication réelle
Hors échantillon	Évalué sur une période que le modèle n'a pas vue à l'entraînement
Vol targeting	Ajuster l'exposition pour garder un niveau de risque constant